


MOVIELENS HYBRID RECOMMENDATION SYSTEM

Product Requirements Document (PRD) & System Design Specification

History-Based Switching with Optional Fusion

Phiên bản tiếng Việt - giữ nguyên technical keywords bằng English



Mục lục

1. Tóm tắt điều hành
2. Tổng quan sản phẩm cho khách hàng
3. Mục tiêu, Non-goals và Success Criteria
4. User Journeys và Functional Capabilities
5. Scope và mức độ triển khai
6. Nền tảng dữ liệu và Data Contracts
7. System Architecture
8. Offline Analytics & Modeling
9. Recommendation Logic và Algorithms
10. Online Serving
11. Feedback và Periodic Model Refresh
12. Evaluation Strategy
13. Storage và Data Models
14. API và Event Contracts
15. Non-Functional Requirements
16. Performance và Scalability Evidence
17. Validation và Reproducibility
18. Security, Privacy và Responsible Design
19. Observability và Operations
20. Implementation Plan
21. Risks, Trade-offs và Open Decisions
22. BDA501 Requirement Traceability
23. Glossary
24. References

1. Tóm tắt điều hành

MovieLens Hybrid Recommendation System là một nền tảng recommendation có khả năng mở rộng, chuyển dữ liệu rating lịch sử và các rating events mới thành danh sách Top-N movie recommendations được cá nhân hóa. Thiết kế chủ động tách Data Ingestion, Offline Analytics/Modeling, Online Serving độ trễ thấp và Periodic Model Refresh để từng concern có thể mở rộng, kiểm thử và thay đổi độc lập.

Trải nghiệm recommendation thay đổi theo lượng thông tin mà hệ thống đang có về user:

- 0 history: trả về Popularity Top-N an toàn, ổn định và có minimum support.
- Few history: khai thác Content-Based từ các movie user đã rating tốt; có thể optional fusion với Popularity để giảm rủi ro do history còn thưa.
- Enough history: dùng ALS Collaborative Filtering làm nguồn personalization chính; có thể bổ sung content similarity khi cần.

Điểm trọng tâm của project không phải "chạy ALS trên MovieLens", mà là xây dựng một end-to-end Big Data system có data lifecycle, model lifecycle, serving lifecycle, feedback loop, validation và performance evidence rõ ràng.

2. Tổng quan sản phẩm cho khách hàng

2.1 Hệ thống giải quyết vấn đề gì?

Một movie catalog lớn tạo ra discovery problem: user không thể tự xem xét toàn bộ nội dung, trong khi một danh sách "most popular" duy nhất bỏ qua sở thích cá nhân. Hệ thống giảm search cost bằng cách chọn và xếp hạng một tập movie nhỏ, có liên quan hơn với từng user.

2.2 User nhận được gì?

- Personalized Top-N recommendations cho user có đủ rating history.
- Fallback recommendations hữu ích cho new user hoặc user có rất ít history.
- Content-aware suggestions dựa trên similarity với các movie user đã thích.
- Recommendation response loại bỏ movie user đã rating khi latest history có sẵn.
- Serving vẫn hoạt động bằng current model version trong lúc candidate model mới được train và validate.

2.3 Vì sao đây là Big Data system?

Project không được xem là Big Data chỉ vì dataset có hàng chục triệu ratings. Big Data evidence nằm ở distributed processing, các joins/aggregations tạo shuffle, scalable model training, batch + streaming ingestion, storage optimization và controlled performance experiments. Kiến trúc cho phép tăng partitions/executors khi workload tăng thay vì phải thiết kế lại toàn bộ pipeline.

3. Mục tiêu, Non-goals và Success Criteria

3.1 Goals

- Xây dựng reproducible end-to-end pipeline từ raw MovieLens đến Analytics, Recommendation, Serving và Feedback.
- Cung cấp personalized recommendation với cold-start handling rõ ràng.
- Minh chứng distributed data engineering bằng PySpark, Parquet, Spark SQL và một MapReduce workload có ý nghĩa.
- Đánh giá recommendation bằng cả prediction metrics và ranking metrics.
- Cung cấp system-performance evidence bằng ít nhất một controlled experiment.
- Dùng MongoDB làm low-latency serving store và có write/read-back evidence.
- Thiết kế streaming path để rating mới cập nhật serving state và sau đó ảnh hưởng periodic retraining.

3.2 Non-goals

- Xây dựng Netflix clone ở production scale hoặc full movie-streaming platform.
- Suy luận age, gender, location hay demographics không tồn tại trong MovieLens 32M.
- Retrain ALS sau từng rating event.
- Dùng BERT/GPT chỉ để tăng độ mới khi core data modality là user-item-rating interaction.
- Cam kết content-safety filtering nếu chưa có user age/parental setting và movie certification từ nguồn đáng tin cậy.

3.3 Success Criteria

Nhóm tiêu chí	Success Criteria
Data	Pipeline tạo Curated Parquet có schema rõ, data-quality checks và reconciliation.
Analytics	MapReduce và Spark SQL cho kết quả kiểm chứng được; có explain(formatted) evidence.
ML	ALS được so sánh với baseline; RMSE, Recall@K và NDCG@K được định nghĩa đúng theo task.
Serving	MongoDB lưu serving artifacts và API có thể đọc Top-N theo userId.
Streaming	Rating event đi qua Kafka/Structured Streaming, cập nhật curated data và user-history state.
Lifecycle	Candidate model chỉ được activate sau Validation / Promotion Gate.
Performance	Có controlled experiment, ví dụ CSV vs Parquet, với các điều kiện được giữ cố định.

4. User Journeys và Functional Capabilities

4.1 Journey A - user chưa có usable history

1. Request: User gọi Recommendation API.
2. History check: API đọc interaction_count / User History từ MongoDB serving state.

3. Strategy: nếu history = 0, router chọn Popularity Top-N.
4. Filtering: áp dụng latest-history exclusion và optional policy filter nếu đủ dữ liệu.
5. Response: trả Top-N ngay mà không invoke ALS training.

4.2 Journey B - user có few ratings

6. Profile: dùng latest User History để xác định các movie được rating tích cực.
7. Content candidates: lấy Precomputed Similar-Movie Lists cho các movie này.
8. Optional fusion: có thể merge với Popularity để ổn định sparse-history recommendation.
9. Re-rank: Exclude Already-Rated và thực hiện Lightweight Re-rank.
10. Response: trả Top-N.

4.3 Journey C - user có enough history

11. Primary source: đọc Precomputed ALS Top-N.
12. Optional complement: có thể thêm content candidates để cải thiện diversity hoặc sparse areas.
13. Re-rank: áp dụng latest-history exclusion và optional policy constraints.
14. Response: trả Top-N mà không chạy Spark training trong request path.

5. Scope và mức độ triển khai

Mức	Nội dung
Core - phải implement	PySpark ETL, Curated Parquet, MapReduce, Spark SQL, Movie Mean baseline, ALS, RMSE, Top-N, MongoDB, validation, performance experiment.
Recommended	Popularity fallback, Content-Based similar-movie lists, history router, Recall@K/NDCG@K, feedback simulation.
Prototype nếu đủ thời gian	Kafka + Structured Streaming demo, immediate User History update.
Design-only / extension	Age/content policy filter, external certification enrichment, cluster/cloud production deployment, ANN/vector search nếu catalog lớn hơn.

6. Nền tảng dữ liệu và Data Contracts

6.1 Dataset facts

MovieLens 32M có 32,000,204 ratings và 2,000,072 tag applications trên 87,585 movies từ 200,948 users. Mỗi user trong dataset đã rating ít nhất 20 movies và dataset không cung cấp demographics. [R1]

File	Schema chính	Vai trò
ratings.csv	userId, movieId, rating, timestamp	Primary explicit-feedback interaction table.
movies.csv	movieId, title, genres	Movie metadata cho joins, Analytics và content features.
tags.csv	userId, movieId, tag, timestamp	Optional content signal và tag Analytics.
links.csv	movieId, imdbId, tmdbId	External identifier mapping; dùng

		cho future enrichment nếu cần.
--	--	--------------------------------

6.2 Canonical rating schema

Column	Type	Ý nghĩa	Validation
userId	integer	Anonymized user identifier	Not null; positive integer.
movieId	integer	Movie identifier	Not null; cần map được sang movies.csv nếu dùng enriched Analytics.
rating	double	Explicit rating	0.5-5.0, bước 0.5.
timestamp	long -> timestamp	Unix epoch seconds	Convert sang timestamp; có thể giữ giá trị gốc để audit.

6.3 Curated dataset contract

- Dùng Explicit Schema; không phụ thuộc CSV type inference cho critical fields.
- Invalid/null records phải được đếm và xử lý deterministic.
- ratings được join với movie metadata bằng movieId cho Analytics/Content use cases.
- Raw data và Curated data phải tách logic để downstream jobs không lặp lại cleaning.
- Curated Parquet là single logical source cho Analytics, Modeling, Evaluation và Scheduled Retraining.

7. System Architecture

Kiến trúc tách rõ data preparation, offline intelligence, online response và model lifecycle. Core data flows dùng đường liền; policy/eligibility filtering chỉ là extension nếu chưa có external age/certification data.




Figure 1. Final target architecture - History-Based Switching with Optional Fusion

7.1 Layer 1 - Data Ingestion & Curated Storage

Historical MovieLens files được xử lý bằng PySpark Batch ETL. Rating events mới đi qua Kafka và Spark Structured Streaming, được lưu vào Raw Event Storage, sau đó Validate / Transform trước khi append vào Curated Parquet. Event đã validate cũng cập nhật online User History / interaction_count trong MongoDB.

7.2 Layer 2A - Offline Analytics & Modeling

Curated data cấp dữ liệu độc lập cho MapReduce Statistics, Spark SQL Analytics và Recommendation Modeling. Recommendation không phải workload duy nhất; việc tách này giúp traceability với BDA501 và làm rõ trách nhiệm của từng subsystem.

7.3 Layer 2B - Online Serving

Recommendation request không retrain ALS. Request path chỉ đọc User History, chọn một hoặc nhiều serving sources đã chuẩn bị sẵn, Exclude Already-Rated, optional Policy/Fusion và trả Top-N.

7.4 Layer 3 - Feedback & Periodic Model Refresh

Accumulated curated data kích hoạt Scheduled Retraining. Candidate Model Version phải đi qua Validation / Promotion Gate trước khi Regenerate Serving Artifacts và Publish / Activate. Current version tiếp tục serve đến khi promotion thành công.

8. Offline Analytics & Modeling

8.1 MapReduce workload

Workload phù hợp là movie-level rating statistics. Combiner state phải mergeable dưới dạng `(sumRating, count)`, không được lấy average của các averages.

Stage	Input	Operation	Output
Mapper	movieId, rating	emit movieId -> (rating, 1)	Key-value partial statistics
Combiner	grouped mapper outputs	sum partial sums và counts	movieId -> (partialSum, partialCount)
Shuffle / Group	mapper/combiner output	group by movieId	all partials per movie
Reducer	partials per movie	totalSum, totalCount, avg=totalSum/totalCount	movieId, count, avgRating
Validation	same curated sample	compare với Spark groupBy	matching counts/averages

8.2 Spark SQL Analytics

- Most-rated movies
- Highly-rated movies có minimum support
- Genre-level rating patterns
- User rating activity
- Temporal rating activity

Ít nhất một formatted physical plan phải được giữ làm evidence. Review cần nhận diện Scan, Filter, Exchange/shuffle, HashAggregate và join strategy khi có.

9. Recommendation Logic và Algorithms

9.1 History-based strategy router

History tier	Primary source	Optional complement	Rationale
0 history	Popularity Top-N	None hoặc onboarding	Chưa có personalized latent/content profile.
Few history	Content-Based similar-movie lists	Popularity	Khai thác known likes nhưng không over-trust sparse collaborative factors.
Enough history	Precomputed ALS Top-N	Content-Based	Collaborative pattern trở thành primary signal.

Threshold giữa “few” và “enough” là configurable design parameter. Cần kiểm chứng bằng experiment, không xem là universal constant.

9.2 ALS Collaborative Filtering

ALS là primary collaborative model vì core interaction data có dạng `(userId, movieId, rating)`. Spark ALS factorizes user-item preferences thành user latent factors và item latent factors, sau đó luân

phiên tối ưu bằng least squares. Spark có tài liệu cho explicit-feedback MovieLens, RMSE evaluation, Top-N generation và cold-start behavior. [R2]

Concept	Định nghĩa
Input	userId, movieId, rating
Learned representation	User latent-factor vector và movie latent-factor vector
Prediction	dot product giữa user factor và movie factor tạo preference/rating score
Training	alternately fix item factors và solve user factors, sau đó fix user factors và solve item factors
Cold start	unknown user/item có thể chưa có factor; hệ thống cần fallback routing

9.3 Content-Based Recommendation

Implementation ưu tiên của project là offline precomputation của Similar-Movie Lists bằng movie content signals như genres và optional tags. Cách này tránh phải đưa ANN/vector-search subsystem vào online path của course prototype.

15. Feature construction: encode genres thành multi-hot features; optional thêm tag TF-IDF features.
16. Similarity: tính movie-to-movie cosine similarity hoặc similarity measure có tài liệu rõ.
17. Precompute: lưu Top-M similar movies cho mỗi movie.
18. Online lookup: dùng positively rated/latest User History để lấy similar candidates.
19. Fusion: optional combine content candidates với Popularity cho sparse-history users.

9.4 Popularity Baseline và Fallback

Popularity vừa là Top-N baseline, vừa là serving strategy cho 0-history users. Để tránh movie chỉ có một rating cao bất thường, cần minimum support và/hoặc weighted score thay vì chỉ sort raw average rating.

10. Online Serving

20. Request: client gọi Recommendation API với userId.
21. State lookup: API đọc User History / interaction_count từ MongoDB.
22. Route: chọn 0 / Few / Enough history.
23. Retrieve: đọc Popularity Top-N, Precomputed Similar-Movie Lists hoặc Precomputed ALS Top-N.
24. Fresh-history exclusion: loại item user vừa rating nhưng chưa kịp phản ánh trong ALS artifacts.
25. Optional policy / fusion: chỉ áp dụng khi đủ source data và strategy yêu cầu.
26. Lightweight Re-rank: merge/rank nhẹ, không chạy Spark training.
27. Response: trả Top-N kèm strategy, modelVersion và generatedAt.

11. Feedback và Periodic Model Refresh

Streaming ingestion là continuous, nhưng ALS retraining là periodic batch. Kiến trúc không tuyên bố online ALS update sau từng event.

Bước	Mô tả
------	-------

1. Rating event	User gửi rating mới.
2. Kafka	Event transport và decoupling.
3. Structured Streaming	Đọc stream, checkpoint, validate/transform.
4. Curated update	Append event đã validate vào Curated Parquet.
5. Serving-state update	Update User History / interaction_count trong MongoDB.
6. Scheduled Retraining	Dùng accumulated curated data để train Candidate Model Version.
7. Validation / Promotion Gate	So sánh metric, sanity checks và policy trước promotion.
8. Publish / Activate	Regenerate serving artifacts và activate version mới; current version vẫn serve đến khi thành công.

12. Evaluation Strategy

12.1 Rating Prediction Evaluation

Compared methods	Metric	Interpretation
Movie Mean baseline vs ALS	RMSE	Lower is better; đo rating-prediction error trên held-out observed ratings.

12.2 Ranking Evaluation

Compared methods	Metrics	Interpretation
Popularity / Content / ALS	Recall@K, NDCG@K	Recall đo khả năng retrieve relevant items; NDCG thưởng relevant items xuất hiện ở vị trí cao hơn.

Relevant item phải được định nghĩa trước khi chạy ranking evaluation, ví dụ `rating >= 4.0` trong held-out set. Nếu dùng random split cho MVP, report phải nêu rõ limitation; temporal holdout là lựa chọn mạnh hơn để mô phỏng “past predicts future”.

13. Storage và Data Models

Logical collection / artifact	Key	Example contents
user_recommendations	userId	modelVersion, generatedAt, strategy, recommendations[]
user_history	userId	interaction_count, recent/positive movieIds, lastUpdated
popular_movies	scope/version	ranked popularity list + support/statistics
similar_movies	movieId	Top-M similar movieIds + similarity scores

MongoDB là Serving Store, không phải training store. Curated Parquet là nguồn phân tích/huấn luyện; MongoDB tối ưu cho read path theo userId/movieId.

14. API và Event Contracts

14.1 Recommendation API

Item	Specification
Endpoint	GET /recommendations/{userId}?k=10
Input	userId, optional k
Output	userId, strategy, modelVersion, generatedAt, recommendations[]
Behavior	History-based switching; fresh-history exclusion; optional fusion/re-rank
Failure fallback	Nếu user-specific artifact unavailable, trả validated Popularity fallback và log reason

14.2 Rating Event Contract

Field	Type	Notes
eventId	string	Unique id cho idempotency/deduplication nếu implement.
userId	integer	Anonymized user id.
movieId	integer	Movie id.
rating	double	0.5-5.0.
timestamp	timestamp	Event time.
source	string	Optional source/application identifier.

15. Non-Functional Requirements

Category	Requirement
Latency	Online recommendation phải serve từ prepared artifacts; Spark training không chạy trong request path.
Scalability	Batch workloads dùng Spark partitions/executors; tránh collect full dataset về driver.
Availability	Current serving version hoạt động trong lúc candidate versions được train/evaluate.
Consistency	User History serving state cập nhật từ validated rating events, có deterministic deduplication khi có thể.
Reproducibility	Document seeds, package versions, Spark configs và commands.
Explainability	Expose strategy source (Popularity/Content/ALS), dù latent factors không trực tiếp human-interpretable.
Maintainability	Data contracts, artifact versioning và tách offline/online responsibilities rõ ràng.

16. Performance và Scalability Evidence

Controlled experiment đề xuất: CSV vs Parquet trên cùng logical workload. Mục tiêu là chứng minh ảnh hưởng của storage format và execution plan bằng số đo, không chỉ bằng nhận định.

Control	Giữ cố định
Hardware	same CPU/RAM/storage
Spark config	same executors/cores/memory
Workload	same query/transformation
Input subset	same logical records
Partitioning	same intended parallelism khi so sánh được
Measurement	same timing method; ghi warm-up và số lần lặp

Evidence cần lưu: execution time, query plan, Exchange/shuffle, data scan và bất kỳ thay đổi join strategy nào có ý nghĩa.

17. Validation và Reproducibility

Validation checkpoint	Evidence
Raw ingestion	file presence, schema, expected row counts
Cleaning	invalid/null/duplicate counts before/after
Join	matched/unmatched movieId counts
MapReduce	compare output với Spark groupBy
SQL	manual sample checks + explain(formatted)
ALS	RMSE + sanity checks + coldStartStrategy documented
Top-N	already-rated items excluded
MongoDB	write + read-back by userId
Streaming	event xuất hiện trong raw/curated + User History update
Retraining	candidate version + pass/fail gate + current-version continuity
Performance	repeated controlled measurements
Reproducibility	requirements/dependencies, versions, seeds, exact commands

18. Security, Privacy và Responsible Design

- Không infer demographics không có trong MovieLens.
- Không lưu PII ngoài phạm vi dataset; userId chỉ là anonymized identifier.
- Policy / Eligibility Filter là DESIGN-ONLY nếu chưa có authoritative age/certification data.
- Kafka/MongoDB credentials phải tách khỏi source code, quản lý bằng environment variables hoặc secret mechanism tương đương.
- API cần input validation, bounded k và logging phù hợp.

19. Observability và Operations

Signal	Examples
Data quality	invalid rate, join miss rate, duplicate rate
Batch pipeline	job duration, task failures, shuffle read/write, executor utilization
Streaming	input rows/sec, processing rows/sec, lag, checkpoint health
Model	RMSE, Recall@K, NDCG@K, coverage, artifact timestamp

Serving	request latency, hit/fallback rate, strategy distribution, error rate
Lifecycle	active modelVersion, candidate version, promotion result

20. Implementation Plan

Phase	Deliverables
1. Verify & setup	rubric traceability, environment, dataset download instructions, schemas
2. Data Engineering	ingestion, data-quality checks, Curated Parquet
3. Analytics	MapReduce, Spark SQL, explain plans
4. Recommendation MVP	Movie Mean, Popularity, ALS, RMSE, Top-N
5. Serving	MongoDB schema, write/read-back, API prototype
6. Ranking & cold start	Recall@K/NDCG@K, content Similar-Movie Lists, history router
7. Feedback/Streaming	Kafka simulation, Structured Streaming, User History update
8. Lifecycle	Scheduled Retraining, Promotion Gate, artifact versioning
9. Performance & validation	controlled experiment, end-to-end verification
10. Packaging	README, report, diagrams, demo, contribution statement

21. Risks, Trade-offs và Open Decisions

Risk / decision	Impact	Mitigation / decision rule
Cold start là synthetic trong MovieLens 32M	Không có true new-user examples	Mask User History và disclose simulation.
Few-history threshold	Ảnh hưởng routing quality	Xem là tunable parameter; test nhiều thresholds.
Random split leakage	Có thể overstate temporal recommendation quality	Ưu tiên temporal holdout nếu khả thi; document nếu dùng random split.
Score fusion giữa heterogeneous sources	ALS/Content/Popularity scores khác scale	Normalize hoặc dùng rank-based fusion; document formula.
Stale ALS artifacts giữa các lần retrain	Rating mới chưa đổi latent factors ngay	Fresh-history exclusion + periodic retrain; User History update ngay.
Content-only similarity over-specialize	Novelty/diversity thấp	Optional Popularity/Content fusion hoặc diversity re-rank.
Policy filter thiếu source data	Không enforce age restriction chính xác	Giữ DESIGN-ONLY đến khi có authoritative data.
Overengineering	Quá nhiều models/services so với course scope	Ưu tiên core rubric + một meaningful improvement; label design-only rõ.

22. BDA501 Requirement Traceability

Requirement area	Architecture / evidence
Big Data justification	distributed ETL, joins/shuffles, scalable model training, batch + streaming design, performance experiment
MapReduce	movie rating statistics với mapper/combiner/shuffle/reducer + Spark validation
PySpark/DataFrames	explicit schema, cleaning, transform, join, Curated Parquet
Spark SQL	multiple analytical queries + explain(formatted)
Spark ML	ALS với evaluation và interpretation
NoSQL	MongoDB serving artifacts + read-back
Streaming	Kafka + Structured Streaming design/prototype với event storage và serving-state update
Cluster/cloud	driver/executor/storage/scaling design; implemented vs design-only ghi rõ
Performance	controlled CSV vs Parquet hoặc experiment tương đương
Reproducibility	versions/config/seeds/commands
Validation	reconciliation và cross-checks xuyên suốt pipeline

23. Glossary

Term	Định nghĩa
Aggregation	Gom nhiều records theo group rồi tính summary như count, sum, average, min, max.
ALS	Alternating Least Squares - Collaborative Filtering algorithm học latent user/item factors.
Baseline	Phương pháp tham chiếu đơn giản để kiểm tra model phức tạp có cải thiện đo lường được hay không.
Cold start	Trường hợp new/sparse-history user hoặc item chưa có đủ interaction data cho collaborative personalization.
Curated data	Dữ liệu đã clean, standardized và validated, sẵn sàng cho Analytics/Modeling.
Hybrid recommender	Hệ thống dùng nhiều recommendation strategies; thiết kế này dùng history-based switching với optional fusion.
NDCG@K	Ranking metric thưởng relevant items xuất hiện gần đầu recommendation list.
Recall@K	Tỷ lệ relevant held-out items được retrieve trong Top-K list.
Serving artifact	Prepared data/model output tối ưu cho online retrieval, ví dụ Popularity Top-N, Similar-Movie Lists, ALS Top-N.
Top-N	Ranked list gồm N recommendations ưu tiên cao nhất cho user.

24. References

[R1] GroupLens Research. MovieLens 32M Dataset README.

[R2] Apache Spark Documentation. Collaborative Filtering / ALS, MLlib.

[R3] Apache Spark Documentation. Structured Streaming and Kafka Integration.

[R4] MongoDB Documentation. Data Modeling / Serving Patterns.

[R5] Covington, P., Adams, J., & Sargin, E. (2016). Deep Neural Networks for YouTube Recommendations - tham khảo kiến trúc candidate generation và ranking.